

RELATÓRIO DE VALIDAÇÃO E FIABILIDADE

S.Y.N.A.P. — Sistema de Geração de Dados Sintéticos

Prova empírica, com processo gerador de verdade fundamental conhecida, de que o dataset sintético produzido pelos 8 módulos recupera a estrutura estatística e causal real, respeita as regras de negócio, é útil, e não expõe dados reais.



Metodologia: dataset de referência com processo gerador conhecido (n=2200) · âncora n=1496 · holdout nunca visto n=704 · sintético gerado n=4500

Sumário executivo

Esta pergunta orienta todo o relatório: **os dados gerados são estatisticamente próximos da realidade, e que testes concretos sustentam essa afirmação?** A resposta curta é: **sim, com nuances honestas e documentadas** — a estrutura relacional e causal é recuperada com grande precisão; a correspondência marginal exacta de algumas colunas numéricas, e a utilidade preditiva para uma tarefa de regressão fina, mostram margem de melhoria que este relatório não esconde.

VEREDITO GLOBAL: estrutura causal e relacional recuperada com alta fidelidade; validação lógica perfeita; privacidade aprovada sem reservas; utilidade multi-tarefa abaixo do limiar recomendado numa tarefa de regressão específica.

O que foi testado

- **170 testes automatizados** (pytest), um por comportamento verificável de cada um dos 8 módulos, mais 6 testes de integração end-to-end com os módulos reais — 170/170 aprovados.
- **Um dataset de referência com processo gerador CONHECIDO** (não apenas "parecido" — as correlações verdadeiras entre idade, rendimento, dívida e score de crédito foram fixadas antes de gerar uma única linha), permitindo verificar se o sistema recupera a estrutura real e não apenas uma amostra que parece real por coincidência.
- **Testes estatísticos formais:** Kolmogorov-Smirnov (distribuições marginais), qui-quadrado (proporções categóricas), erro de recuperação de correlação face à verdade fundamental.
- **Prova de utilidade:** Treino-Sintético-Teste-Real (TSTR) vs. Treino-Real-Teste-Real (TRTR), em duas tarefas-alvo de natureza diferente (classificação e regressão).
- **Prova de privacidade:** Distance to Closest Record, Nearest-Neighbour Distance Ratio, correspondência exacta linha-a-linha, e Ataque de Inferência de Pertença.

1. Metodologia — por que um processo gerador conhecido

Comparar um dataset sintético contra uma amostra real arbitrária tem um limite fundamental: se as duas se parecerem, não há forma de saber se o sistema recuperou a estrutura real subjacente, ou se apenas produziu algo estatisticamente plausível por coincidência. A prática padrão em estudos de simulação para validar pipelines geradores é diferente: construir um dataset de referência cujas relações causais e parâmetros estatísticos são **conhecidos à partida**, e verificar se o sistema os recupera a partir apenas de uma amostra observada — exactamente a mesma posição em que o sistema está quando confrontado com dados reais desconhecidos.

Foi construído um dataset de 2200 linhas simulando um cenário de risco de crédito (idade, rendimento, dívida, score de crédito, e uma classificação de risco derivada), com correlações verdadeiras fixadas: idade->rendimento = 0.42, rendimento->dívida = -0.35, rendimento->score = 0.55, dívida->score = -0.50. Este dataset foi dividido de forma honesta: 1496 linhas serviram de âncora (Módulo 1 e referência de treino do Módulo 8), e 704 linhas ficaram de fora de todo o processo de geração — o "holdout nunca visto", usado exclusivamente para os Módulos 7 e 8.

Fluxo executado

Etapa	Módulo	Resultado
Contrato Estatístico	M1 — Neocórtex Percetual	fonte=csv_real, 4 correlações, n=1496
DAG + Semente	M2 — Hipocampo	5000 linhas, erro médio de correlação=0.043
Remistura + ASP + Artefactos	M3 + M4 + M5 — Núcleo	4500 linhas aprovadas, em 5 lotes
Deriva causal + ILP	M4 — Hipotálamo	0 derivas detectadas, 0 regras induzidas
Homeostasia	M6	monitorização contínua por lote (ver Secção 4)
Validação final + Modelo Gémeo	M7 — Compilador	ASP 4500/4500, Índice=0.9999
Utilidade + Privacidade	M8 — Auditor	utilidade=75.2%, privacidade=aprovada

Suite de testes automatizados

Cada módulo tem o seu próprio conjunto de testes unitários, construídos durante o desenvolvimento incremental do sistema — não escritos depois, para validar o que já existia, mas antes/durante cada módulo, cobrindo casos de sucesso, casos-limite e casos de erro esperados. A suite completa corre em menos de um minuto.




Figura 1 — Testes automatizados aprovados por módulo (170/170, incluindo 6 testes de integração end-to-end não representados individualmente no gráfico).

Módulo	Testes	Foco principal
M1 — Neocórtex Percetual	28	Contrato estatístico, validação de amostra, parâmetros manuais
M2 — Hipocampo	30	DAG, d-separação, BIC, geração da semente
M3 — Expansor	20	Mahalanobis, plausibilidade, remistura, atenção negativa
M4 — Hipotálamo	22	ASP, deriva causal contínua, indução de regras (ILP)
M5 — Núcleo	12	Autoencoder, detecção de artefactos, atenção negativa em tempo real
M6 — Homeostase	14	KL-divergência, entropia, reponderação
M7 — Compilador	18	Validação ASP final, Modelo Gémeo, Índice de Fidelidade
M8 — Auditor	20	TSTR/TRTR, DCR, NNDR, MIA, correspondência exacta
Integração end-to-end	6	Pipeline completo com os 8 módulos reais
Total	170	170/170 aprovados (100%)

3. Fidelidade estatística — distribuições e correlações

A primeira pergunta concreta: as colunas geradas têm a mesma forma (média, dispersão, forma da distribuição) que os dados reais nunca vistos durante a geração?




Figura 2 — Distribuições do holdout real (nunca usado na geração) sobrepostas às do dataset sintético, para as 4 colunas numéricas.




Figura 3 — Matriz de correlação de Pearson: holdout real vs. sintético gerado.

Teste formal: Kolmogorov-Smirnov (indistinguibilidade das distribuições)

O teste de Kolmogorov-Smirnov testa a hipótese nula de que duas amostras vêm da mesma distribuição contínua. Um p-valor > 0.05 significa que não há evidência estatística para rejeitar essa hipótese — ou seja, as distribuições são estatisticamente indistinguíveis a esse nível de confiança.

Indistinguibilidade estatística: sintético vs. real (holdout)




Figura 4 — P-valor do teste KS por coluna. Barras verdes: indistinguível de real ($p>0.05$). Barras vermelhas: diferença estatisticamente detectável.

Coluna	Estatística D	p-valor	Veredito ($\alpha=0.05$)
idade	0.037	3.71e-01	Indistinguível
rendimento	0.063	1.62e-02	Diferença detectável
divida	0.101	6.94e-06	Diferença detectável
score_credito	0.061	1.94e-02	Diferença detectável

Leitura honesta: apenas a coluna *idade* passa o teste KS a $\alpha=0.05$. As restantes três colunas numéricas mostram uma diferença estatisticamente detectável face ao holdout real, com estatísticas D entre 0.061 e 0.101 — desvios pequenos em termos absolutos (visíveis na Figura 2 como sobreposições quase completas), mas reais, e não escondidos aqui. Com 4500 linhas sintéticas testadas contra 704 reais, o teste KS tem elevada potência estatística: consegue detectar diferenças pequenas que seriam invisíveis a olho nu ou irrelevantes na prática. É precisamente por isto que o Módulo 6 (Homeostasia) e o Módulo 8 (Auditor) existem — para quantificar se essas diferenças, embora estatisticamente reais, ainda permitem utilidade prática (Secção 6).

Proporções categóricas ("risco")




Figura 5 — Proporções de cada categoria de risco (esquerda) e score de crédito médio por categoria (direita), real vs. sintético.

O teste de qui-quadrado às proporções de *risco* devolve $\chi^2=72.0$, $p=2.26e-16$ — uma diferença claramente significativa. Em termos absolutos, a categoria "alto risco" está sub-representada no sintético (18.6% vs. 23.7% no real, uma diferença de ~5 pontos percentuais), enquanto a relação *direção* entre score de crédito e categoria de risco está correcta (painel direito da Figura 5: o score médio por categoria segue a mesma ordem baixo > médio > alto em ambos). O sistema aprendeu bem a *regra*, mas calibrou de forma ligeiramente conservadora o desequilíbrio das classes mais raras.

4. Recuperação da estrutura causal

Mais exigente do que comparar contra uma amostra real é comparar contra o **processo gerador verdadeiro** — os coeficientes de correlação que foram fixados antes de qualquer linha existir, e que nem a própria amostra real reproduz exactamente (ela própria é uma amostra finita e ruidosa desse processo).




Figura 6 — Cada correlação comparada contra: o processo gerador verdadeiro, a amostra real (holdout), e o sintético gerado.

Par de colunas	Verdade fundamental	Real (amostra)	Sintético	Erro abs. (vs. verdade)
idade-rendimento	0.420	0.433	0.429	0.009
rendimento-divida	-0.350	-0.352	-0.326	0.024
rendimento-score_credito	0.550	0.552	0.554	0.004
divida-score_credito	-0.500	-0.529	-0.494	0.006

O erro absoluto médio do sintético face à verdade fundamental é **0.0104** — comparável, e nalguns pares até menor, do que o erro da própria amostra real face à verdade fundamental (a amostra real também é finita e sofre ruído amostral). Isto é a prova mais forte disponível de que o sistema não está apenas a memorizar ou a aproximar a amostra observada — está a recuperar o processo gerador subjacente.

O papel da DAG causal (Módulo 2): uma limitação honesta

O Módulo 2 só liga uma coluna categórica a uma numérica através de uma aresta na DAG. Para quantificar o impacto real desta decisão de arquitectura, a semente foi gerada duas vezes: uma com a DAG completa fornecida pelo utilizador, outra sem qualquer DAG (o modo de aprendizagem automática, que neste sistema não liga categóricas a numéricas — ver PROJECT_NARRATIVE.md).

Efeito de fornecer a DAG causal (limitação documentada do Módulo 2)




Figura 7 — Associação (eta²) entre risco e score de crédito: verdade real vs. semente com DAG vs. semente sem DAG.

A associação real é 0.815 (eta²); com a DAG fornecida, a semente recupera 0.805 — muito próximo. Sem qualquer DAG, a associação colapsa para 0.0004 — essencialmente zero. **Esta é a prova quantitativa de que fornecer a estrutura causal não é opcional** quando existem dependências categórica-numérica fortes no domínio: sem ela, o sistema ainda produz marginais e correlações numéricas correctas, mas perde por completo a relação entre tipos de coluna diferentes.

5. Validação lógica (ASP) e comportamento do gerador

Das 4705 linhas quimera candidatas testadas pelo Núcleo (Módulos 3+4+5) ao longo de 5 lotes, 4500 foram aprovadas. A validação ASP final do Compilador (Módulo 7) confirma **4500/4500 linhas (100%)** em conformidade com as regras de negócio (rendimento > 0 , dívida ≥ 0) — zero exceções, sem atalhos, na verificação exaustiva final.




Figura 8 — Motivos de rejeição das linhas quimera candidatas ao longo de todo o processo de geração.

A distância de Mahalanobis foi o filtro mais activo (195 rejeições), consistente com o seu papel de primeira linha de defesa contra combinações estatisticamente improváveis; o autoencoder do Núcleo apanhou 10 artefactos adicionais que passaram os filtros estatísticos mas ainda assim não correspondiam a nenhuma região da variedade aprendida na semente. Nenhuma linha foi rejeitada por violar as regras de negócio durante a geração — eram já respeitadas pela própria distribuição-alvo do Contrato.

Homeostasia — divergência ao longo dos lotes




Figura 9 — Divergência suavizada (EMA) por coluna, a cada um dos 5 lotes gerados.

A divergência global suavizada oscilou entre 4.8% e 6.7% ao longo dos 5 lotes, permanecendo sempre **abaixo do limiar crítico de 10%** — nunca justificando uma pausa da geração — mas também sem convergir de forma estável para o estado "normal" (<5%): 1 dos 5 lotes ficaram em "normal", os restantes 4 em "atenção". Isto reflecte honestamente as mesmas três colunas que o teste KS já tinha sinalizado (Secção 3) — o sistema está a monitorizar e a reagir correctamente, mas o volume gerado neste ensaio (4 500 linhas, 5 lotes) não foi suficiente para uma convergência completa. A Secção 9 recomenda um volume maior para observar convergência total.

6. Utilidade — TSTR vs. TRTR (Módulos 7 e 8)

Este é o teste mais próximo de "os dados servem para o que um cliente real precisa": treinar um modelo preditivo no sintético (Treino-Sintético-Teste-Real) e comparar com um modelo idêntico treinado no real (Treino-Real-Teste-Real), ambos avaliados no MESMO conjunto de teste real, nunca visto por nenhum dos dois.

Módulo 8 — Utilidade: Treino-Sintético-Teste-Real (TSTR) vs. Treino-Real-Teste-Real (TRTR)




Figura 10 — Desempenho TSTR vs. TRTR em duas tarefas-alvo de natureza diferente.

Tarefa (coluna-alvo)	Métrica	Sintético (TSTR)	Real (TRTR)	Retenção de utilidade
risco	AUC	0.9993	0.9999	99.9%
score_credito	RMSE	138.6678	70.0419	50.5%

O Módulo 7 usa apenas a tarefa de classificação (*risco*) para o seu Índice de Fidelidade — 0.9999, muito acima do limiar de 0.90, e por isso **libertou** a saída. É uma verificação genuína, mas de **uma só tarefa**. O Módulo 8 (Auditor) avalia a mesma classificação MAIS uma tarefa de regressão (prever *score_credito* numericamente) — uma tarefa objectivamente mais difícil de replicar em fidelidade fina — e aí a retenção cai para 50.5%. A retenção média das duas tarefas (75.2%) fica **abaixo do limiar recomendado de 85%**, e o Auditor reprova a utilidade global.

Achado central deste relatório: com uma única tarefa-alvo, o sistema pareceria quase perfeito (99.99%). Com duas tarefas de natureza diferente, um problema real aparece. É exactamente para isto que o Módulo 8 foi construído como uma segunda verificação independente, e não apenas uma repetição do Módulo 7.

7. Privacidade — memorização e inferência de pertença

Módulo 8 — Privacidade: memorização e inferência de pertença




Figura 11 — Distance to Closest Record (esquerda) e Ataque de Inferência de Pertença (direita).

Verificação	Resultado	Interpretação
DCR sintético -> real (mediana)	0.481	distância no espaço padronizado
DCR real -> real (baseline)	0.500	distância esperada entre duas amostras reais
Razão DCR (sint./real)	0.963	≥ 0.5 é saudável; muito abaixo sugere memorização
Linhas sintéticas suspeitas	0	nº de linhas anormalmente próximas de uma real
Correspondências exactas	0	linhas sintéticas idênticas a uma real
NNDR sintético / real (baseline)	0.843 / 0.819	razão de distância ao 1º/2º vizinho mais próximo
Ataque de Inferência de Pertença (AUC)	0.537	0.5 = ataque não distingue; seguro

Todos os quatro sinais de privacidade estão dentro dos limites saudáveis: a razão de DCR (0.96) está muito próxima de 1 — o sintético não está anormalmente mais próximo dos dados reais do que duas amostras reais estariam entre si. Zero correspondências exactas e zero linhas suspeitas. O Ataque de Inferência de Pertença, treinado com acesso à âncora real usada para gerar o sistema, obtém uma AUC de 0.537 — estatisticamente indistinguível de 0.5 (adivinhar ao acaso) dentro da tolerância definida. **A privacidade foi aprovada sem reservas.**

8. Veredito consolidado

100% REGRAS DE NEGÓCIO (ASP)	0.010 ERRO MÉDIO DE CORRELAÇÃO	0.80 / 0.81 ASSOCIAÇÃO CAUSAL (SINT./REAL)	0.54 AUC DO ATAQUE DE PERTENÇA
---	---	---	---

Dimensão	Resultado	Veredito
Validação lógica (ASP)	4 500/4 500 linhas conformes	Aprovado
Estrutura de correlação	erro médio 0.010 face à verdade fundamental	Aprovado
Estrutura causal (com DAG)	eta² 0.805 vs. 0.815 real	Aprovado
Distribuições marginais (KS)	1/4 colunas indistinguíveis a $\alpha=0.05$	Parcial — documentado
Proporções categóricas (χ^2)	"alto risco" sub-representado ~5pp	Parcial — documentado
Fidelidade (Módulo 7, 1 tarefa)	Índice 1.000	Libertado
Utilidade (Módulo 8, 2 tarefas)	retenção média 75.2%	Reprovado (abaixo do limiar de 85%)
Privacidade (Módulo 8)	DCR, NNDR, correspondência exacta, MIA	Aprovada sem reservas

O sistema recupera com grande fidelidade a estrutura relacional e causal de um processo gerador desconhecido, aplica as suas regras de negócio sem excepções, e protege a privacidade dos dados reais em todas as frentes testadas. A utilidade preditiva é excelente para tarefas de classificação, mas — honestamente reportado, não escondido — mais modesta para uma tarefa de regressão fina, um resultado que só o desenho de dupla verificação (Módulo 7 + Módulo 8) tornou visível.

9. Limitações e recomendações

- **Volume do ensaio:** 4 500 linhas sintéticas / 5 lotes é suficiente para provar o mecanismo, mas insuficiente para a Homeostasia convergir totalmente a "normal" — recomenda-se repetir com >20 000 linhas e mais checkpoints para observar convergência.
- **Sub-representação de classes raras:** a categoria "alto risco" (a mais rara, 18.7% da população real) ficou cerca de 5 pontos percentuais abaixo do valor real no sintético — candidata a reforço adicional da Homeostasia (Módulo 6) em execuções mais longas.
- **Utilidade específica de tarefa:** o Índice de Fidelidade do Módulo 7 usa uma única tarefa-alvo por omissão; este relatório demonstra que isso pode mascarar défices noutras tarefas — recomenda-se sempre correr o Módulo 8 com múltiplas colunas-alvo antes de confiar cegamente no veredito do Módulo 7.
- **Dependência categórica-numérica exige DAG explícita:** confirmado quantitativamente na Secção 4 — sem uma DAG fornecida pelo utilizador, essas relações não sobrevivem.